

Наивный Байес и вероятностный подход к классификации

Лекция 6



Пример задачи регрессии (омская версия)



Боярышник - 22 рубля 50 копеек

	Вкус	Стоимость
--	-------------	------------------

Анастасия	5	3
------------------	---	---

Александр	5	0
------------------	---	---

Итог: 6,5

Ликбез: вероятность и формула Байеса



Вероятность события

Пусть A – событие. Например,

$A = \{\text{монета выпадет орлом}\}$

$A = \{\text{докладчик помрёт во время лекции}\}$

$A = \{\text{на игральном кубике выпадет 6}\}$

Для событий можно найти их **вероятность** $\Pr(A)$ следующим образом:

Пусть A_1, A_2, \dots, A_n – все элементарные исходы эксперимента, тогда

$\Pr(A) = \{\text{число исходов при которых наблюдается } A\} / n$



Пример 1

Эксперимент: кидаем кубик.

Элементарные исходы: «выпадет 1», ..., «выпадет 6»

Для краткости:

1,2,3,4,5,6

Найдите вероятности следующих событий:

$A = \{\text{выпадет четное число}\}$

$A = \{\text{выпадет число, делящееся на 3}\}$

$A = \{\text{выпадет делитель числа 6}\}$

$A = \{\text{выпадет отрицательное число}\}$

$A = \{\text{выпадет число меньше 10}\}$



Пример 2

Эксперимент: заводим двоих детей.

Элементарные исходы (М – мальчик, Д- девочка):

ММ,МД,ДМ,ДД

Найдите вероятности следующих событий:

$A = \{\text{дети будут разного пола}\}$

$A = \{\text{будет хотя бы одна девочка}\}$

$A = \{\text{старшим ребенком будет мальчик}\}$

$A = \{\text{число девочек не равно числу мальчиков}\}$



Условные вероятности

$\Pr(A|B)$ (читается как «вероятность A при условии B»)

Условная вероятность считается по правилу:

1. Мысленно представьте, что событие B **уже произошло**.
2. Удалите элементарные исходы, которые **НЕ** удовлетворяют событию B.
3. Найдите вероятность события A для нового множества элементарных исходов, используя формулу с предыдущих слайдов.



Пример 1*

Эксперимент: кидаем кубик.

Элементарные исходы:

1,2,3,4,5,6

Найдите вероятность $\Pr(A|B)$ для :

- 1) $A = \{\text{выпадет четное число}\}$, $B = \{\text{выпадет число, делящееся на 3}\}$
- 2) $A = \{\text{выпадет 6}\}$, $B = \{\text{выпадет делитель числа 6}\}$
- 3) $A = \{\text{выпадет 1}\}$, $B = \{\text{выпадет четное число}\}$



Пример 1*

Эксперимент: кидаем кубик.

Элементарные исходы:

1,2,3,4,5,6

Найдите вероятность $\Pr(A|B)$ для :

- 1) $A = \{\text{выпадет четное число}\}$, $B = \{\text{выпадет число, делящееся на 3}\}$
- 2) $A = \{\text{выпадет 6}\}$, $B = \{\text{выпадет делитель числа 6}\}$
- 3) $A = \{\text{выпадет 1}\}$, $B = \{\text{выпадет четное число}\}$

А теперь подсчитайте $\Pr(B|A)$ для пп.1-3



Пример 2*

Эксперимент: заводим двоих детей.

Элементарные исходы (М – мальчик, Д- девочка):

ММ,МД,ДМ,ДД

Найдите вероятность $\Pr(A|B)$ для :

1) $A=\{\text{дети будут разного пола}\}$ $B=\{\text{среди детей есть девочка}\}$

2) $A=\{\text{дети будут разного пола}\}$ $B=\{\text{старший ребенок - девочка}\}$



Пример 2*

Эксперимент: заводим двоих детей.

Элементарные исходы (М – мальчик, Д- девочка):

ММ,МД,ДМ,ДД

Найдите вероятность $\Pr(A|B)$ для :

1) $A=\{\text{дети будут разного пола}\}$ $B=\{\text{среди детей есть девочка}\}$

2) $A=\{\text{дети будут разного пола}\}$ $B=\{\text{старший ребенок - девочка}\}$

А теперь подсчитайте $\Pr(B|A)$ для пп.1-2



Задача более близкая к проблеме классификации

В выборке 60% женщин и 40% мужчин. Известно, что среди них курит 10% женщин и 70% мужчин. Про человека NN известно, что он курит. С какой вероятностью NN является женщиной (мужчиной)?

Если вы решите эту задачу, то вы **фактически осуществите классификацию** NN (предскажете значение его пола).



Решение

В выборке 60% женщин и 40% мужчин. Известно, что среди них курит 10% женщин и 70% мужчин. Про человека NN известно, что он курит. С какой вероятностью NN является женщиной (мужчиной)?

Обозначим:

$M = \{\text{человек является мужчиной}\}$

$J = \{\text{человек является женщиной}\}$

$K = \{\text{человек курит}\}$

Из условия можно найти

$\Pr(M)$, $\Pr(J)$, $\Pr(K|M)$, $\Pr(K|J)$.



Решение

Имеем:

$$\Pr(M)=0.4, \Pr(Ж)=0.6, \Pr(K|M)=0.7, \Pr(K|Ж)=0.1$$

Из этих чисел можно даже найти $\Pr(K)$:

$$\begin{aligned}\Pr(K) &= \Pr(M)*\Pr(K|M)+\Pr(Ж)*\Pr(K|Ж)=0.4*0.7+0.6*0.1 \\ &=0.34=34\%\end{aligned}$$

Но нас интересуют вероятности несколько других событий (каких?):



Решение

Имеем:

$$\Pr(M)=0.4, \Pr(Ж)=0.6, \Pr(K|M)=0.7, \Pr(K|Ж)=0.1$$

Из этих чисел можно даже найти $\Pr(K)$:

$$\begin{aligned}\Pr(K) &= \Pr(M)*\Pr(K|M)+\Pr(Ж)*\Pr(K|Ж)=0.4*0.7+0.6*0.1 \\ &=0.34=34\%\end{aligned}$$

Но нас интересуют вероятности несколько других событий (каких?):

$$\Pr(M|K)=?$$

$$\Pr(Ж|K)=?$$

А как их найти?



Есть формула Байеса!

$$\Pr(B|A) = \Pr(A|B) * \Pr(B) / \Pr(A)$$

Для нашей задачи получаем:

$$\Pr(M|K) = \Pr(K|M) * \Pr(M) / \Pr(K) = 0.7 * 0.4 / 0.34 = 28/34$$

$$\Pr(Ж|K) = \Pr(K|Ж) * \Pr(Ж) / \Pr(K) = 0.1 * 0.6 / 0.34 = 6/34$$

- фактически мы получили оценки принадлежности «классу мужчин» и «классу женщин»



Что делать с вероятностью при классификации?

На прошлом слайде были получены вероятности принадлежности объекта «классу мужчин» и «классу женщин» ($28/34$ и $8/34$). Что с ними делать, чтобы получить точный (а не вероятностный) ответ?

1. Выбрать класс с наибольшей вероятностью (в данном примере выбрать «мужчин»).
2. С распределением $28/34$ и $8/34$ сгенерировать случайную величину. Ее значение и будет окончательным ответом.



Что делать с вероятностью при классификации?

2. Установить пороговое значение p для вероятности. Если вероятность принадлежности «классу мужчин» больше p , то объект классифицируется как мужчина. Иначе – как женщина.

Такой подход оправдан, когда ущерб от ошибки классификации различен для первого и второго класса (см. пример на след. слайде).



Террорист или нет?

Допустим мы оцениваем не вероятности принадлежности классам «мужчин» и «женщин», а к классам «террористов» и «честных людей».

Допустим, что для человека А были получены вероятностные оценки на принадлежности к классу террористов $6/34$ и к классу «честных людей» $28/34$.

Его «честность» в 4.5 раза выше его терроризма и в соответствии с методами пп1-2 он (скорей всего) будет окончательно отнесен к классу «честных».



Террорист или нет?

Но тут над понимать, что цена ошибки «террориста приняли за честного» **гораздо выше** цены ошибки «честного приняли за террориста». А для объекта А принадлежность террористам не такая уж и маленькая ($6/34=18\%$) – заведомо выше доли террористов в населении страны.

Здесь оправдано установить маленький порог p (например, $p=10\%$) и людей, у которых вероятность принадлежности «классу террористов» больше p , отправлять на дополнительную проверку.



Наивный Байес



А как получить вероятности классов, когда признаков > 1 ?

В задаче про курение нецелевой признак был один («курит или нет»). А если нецелевых признаков больше?

Пусть

	Курит	Любит кошек	Пол (Y)
A	0	1	1
B	0	1	0
C	1	0	1
D	1	0	0
E	1	0	1

	Курит	Любит кошек	Пол (Y)
F	0	0	?



Вычисления для объекта F

Если применять формулу Байеса для объекта F, то нужно будет знать вероятности:

$$\Pr(K' * L' \mid M)$$

$$\Pr(K' * L' \mid Ж)$$

где

$K = \{\text{курит}\}$, $K' = \{\text{не курит}\}$,

$L = \{\text{любит кошек}\}$, $L' = \{\text{не любит кошек}\}$,

$*$ = союз «и».

А как вычислить эти вероятности?



Теорема о произведении вероятности

$$\Pr(A*B)=\Pr(A)*\Pr(B),$$

если события A и B **не зависят** друг от друга.

Решая нашу задачу, сделаем допущение, что курение **НЕ ЗАВИСИТ** от любви к кошкам и наоборот (а в жизни это действительно так?). Тогда мы получаем:

$$\Pr(K'*Л' \mid М)= \Pr(K' \mid М)* \Pr(Л' \mid М),$$

$$\Pr(K'*Л' \mid Ж)= \Pr(K' \mid Ж)*\Pr(Л' \mid Ж),$$

а вероятности из правых частей равенств можно найти по таблице.



Решение примера

Из таблицы получаем вероятности:

$$\Pr(\mathcal{J})=2/5$$

$$\Pr(\mathcal{M})=3/5$$

$$\Pr(\mathcal{K}|\mathcal{J})=1/2$$

$$\Pr(\mathcal{K}'|\mathcal{J})=1/2$$

$$\Pr(\mathcal{K}|\mathcal{M})=2/3$$

$$\Pr(\mathcal{K}'|\mathcal{M})=1/3$$

$$\Pr(\mathcal{L}|\mathcal{J})=1/2$$

$$\Pr(\mathcal{L}'|\mathcal{J})=1/2$$

$$\Pr(\mathcal{L}|\mathcal{M})=1/3$$

$$\Pr(\mathcal{L}'|\mathcal{M})=2/3$$

	Курит	Любит кошек	Пол (Y)
A	0	1	1
B	0	1	0
C	1	0	1
D	1	0	0
E	1	0	1



Решение примера

По формуле Байеса для объекта F получаем вероятности принадлежности классам:

$$\Pr(\text{Ж}|\text{К}'\text{Л}') = \Pr(\text{К}'\text{Л}'|\text{Ж}) * \Pr(\text{Ж}) / \Pr(\text{К}'\text{Л}')$$

$$\Pr(\text{М}|\text{К}'\text{Л}') = \Pr(\text{К}'\text{Л}'|\text{М}) * \Pr(\text{М}) / \Pr(\text{К}'\text{Л}')$$

Используем предположение о независимости курения от любви к кошкам:

$$\Pr(\text{Ж}|\text{К}'\text{Л}') = \Pr(\text{К}'|\text{Ж}) * \Pr(\text{Л}'|\text{Ж}) * \Pr(\text{Ж}) / \Pr(\text{К}'\text{Л}')$$

$$\Pr(\text{М}|\text{К}'\text{Л}') = \Pr(\text{К}'|\text{М}) * \Pr(\text{Л}'|\text{М}) * \Pr(\text{М}) / \Pr(\text{К}'\text{Л}')$$



Решение примера

Подставляем числа:

$$\Pr(\text{Ж}|\text{К}'\text{Л}') = (1/2 * 1/3 * 2/5) / \Pr(\text{К}'\text{Л}') = (1/15) / \Pr(\text{К}'\text{Л}')$$

$$\Pr(\text{М}|\text{К}'\text{Л}') = (2/3 * 1/3 * 3/5) / \Pr(\text{К}'\text{Л}') = (2/15) / \Pr(\text{К}'\text{Л}')$$

Величину $\Pr(\text{К}'\text{Л}')$ можно не вычислять (она нам не нужна), а воспользоваться равенством

$$\Pr(\text{Ж}|\text{К}'\text{Л}') + \Pr(\text{М}|\text{К}'\text{Л}') = 1$$

И получить

$$\Pr(\text{Ж}|\text{К}'\text{Л}') = 1/3 \quad \Pr(\text{М}|\text{К}'\text{Л}') = 2/3$$



Решение примера

Таким образом, принадлежность классу мужчин в 2 раза выше принадлежности классу женщин.

$$\Pr(\text{Ж}|\text{К}'\text{Л}')=1/3 \quad \Pr(\text{М}|\text{К}'\text{Л}')=2/3$$

Вот таким макаром и происходит классификация с помощью формулы Байеса.

Аналогично обрабатываются таблицы с большим числом признаков.



Допущение о независимости признаков

Работа классификатора существенно использует предположение о независимости признаков друг от друга.

Но независимость признаков (когда коэфф. корр=0) не часто наблюдается на практике.

Поэтому наш классификатор называют **наивным байесовским классификатором (НБК)**.

Когда между признаками существует сильная зависимость НБК может сильно ошибаться.



Работа НБК при зависимых признаках

В этой таблице признаки коррелируют (более того: они совпадают).

Проведем расчет принадлежности классам объекта F

1) без использования второго признака,

2) с двумя признаками.

	Курит	Любит кошек	Пол (Y)
F	0	0	?

	Курит	Любит кошек	Пол (Y)
A	0	0	1
B	0	0	0
C	1	1	1
D	1	1	0
E	1	1	1



Используем только один признак

Имеем: $\Pr(\mathcal{K})=2/5$, $\Pr(K'|\mathcal{K})=1/2$, $\Pr(\mathcal{M})=3/5$,
 $\Pr(K'|\mathcal{M})=2/3$

$$\Pr(\mathcal{K}|K') = \Pr(K'|\mathcal{K}) * \Pr(\mathcal{K}) / \Pr(K') = (1/5) / \Pr(K')$$

$$\Pr(\mathcal{M}|K') = \Pr(K'|\mathcal{M}) * \Pr(\mathcal{M}) / \Pr(K') = (2/5) / \Pr(K')$$

Из равенства $\Pr(\mathcal{K}|K') + \Pr(\mathcal{M}|K') = 1$
находим

$$\Pr(\mathcal{K}|K') = 1/3, \Pr(\mathcal{M}|K') = 2/3$$

	Курит	Любит кошек	Пол (Y)
A	0	0	1
B	0	0	0
C	1	1	1
D	1	1	0
E	1	1	1

Используем оба признака

Имеем: $\Pr(\text{Ж})=2/5$, $\Pr(\text{К}'|\text{Ж})=1/2$, $\Pr(\text{Л}'|\text{Ж})=1/2$,
 $\Pr(\text{М})=3/5$, $\Pr(\text{К}'|\text{М})=2/3$, $\Pr(\text{Л}'|\text{М})=2/3$

$\Pr(\text{Ж}|\text{К}'\text{Л}')=\Pr(\text{К}'|\text{Ж})*\Pr(\text{Л}'|\text{Ж})*\Pr(\text{Ж})/\Pr(\text{К}'\text{Л}')=(1/10)/\Pr(\text{К}'\text{Л}')$
 $\Pr(\text{М}|\text{К}'\text{Л}')=\Pr(\text{К}'|\text{М})*\Pr(\text{Л}'|\text{М})*\Pr(\text{М})/\Pr(\text{К}'\text{Л}')=(4/15)/\Pr(\text{К}'\text{Л}')$

Из равенства $\Pr(\text{Ж}|\text{К}'\text{Л}')+\Pr(\text{М}|\text{К}'\text{Л}')=1$
находим

$\Pr(\text{Ж}|\text{К}')=3/11$, $\Pr(\text{М}|\text{К}')=8/11$

	Курит	Любит кошек	Пол (Y)
A	0	0	1
B	0	0	0
C	1	1	1
D	1	1	0
E	1	1	1

Ответ-то изменился!!!

... хотя никакой принципиально новой информации мы в таблицу не добавляли.

Вот к чему приводит наличие зависимостей между признаками!!!

Зависимые признаки нужно удалять (или как-то модифицировать) – об этом в теме «Отбор признаков»



Плюсы НБК:

1. Простота и быстрая работа. Используется в системах массового обслуживания. Например, при фильтрации спама.
2. В некоторых случаях НБК хорошо работает даже для коррелированных признаков (так что стоит рискнуть))). Например, при фильтрации спама признаки, как правило, не являются независимыми – этот эффект и рассмотрим на след. слайдах.



Фильтрация спама (общая постановка)

Задача: есть текст письма, определить является ли оно спамом (класс 1) или нет (класс 0).

Какие признаки есть у письма?

Самый простой способ: для каждого слова из словаря завести свой бинарный признак (он будет равен 1, если это слово встречается в рассматриваемом письме).

Получится примерно как на след. слайде...



Помогите Даше найти зависимые признаки



	лекарство	запой	геморрой	заработать	миллион	Путин	Спам?
A	1	1	1	0	0	0	1
B	1	1	0	0	0	0	1
C	1	0	1	0	0	0	1
D	0	0	0	1	1	0	1
E	1	0	0	0	1	0	1
F	0	0	0	0	1	1	0



Вообще говоря...

... там много зависимых признаков (к тому же объем выборки небольшой).

Но НБК не обязательно на них начнет косячить (проверено на практике)!

Имейте в виду: в задаче про спам очень важно правильно установить порог p классификации.

Напомню смысл порога p : если $\Pr(\text{Спам} \mid \text{текст письма}) > p$, то письмо относим к классу «Спам».

В этой задаче порог **должен быть большим** (а почему?).



Использованная литература

1. Т.Сегаран «Программируем коллективный разум»
(фильтрация спама)

